贝叶斯时空图神经场 (BSTGNF) 的形式化框架

一个被提出的算法框架

2025 年 10 月 22 日

摘要： 本文档旨在为所提出的贝叶斯时空图神经场（BSTGNF）模型构建一个形式化的、端到端的算法框架。该框架主要应用于网络安全领域的分类任务，并重点关注鲁棒的不确定性量化能力。本文将详细阐述问题的定义、模型架构、以及基于贝叶斯原理（特别是变分推断）的训练与推理流程。

1 问题定义与符号表示

我们首先对研究任务进行形式化定义。

- **输入**: 我们将网络流量、攻击、以及其他各类数据建模为一个动态图。
  - 图的拓扑结构由一个邻接矩阵 $\mathbf{A} \in \mathbb{R}^{N \times N}$ 描述，其中 N 为节点数量。为简化问题，我们假设在观测窗口内图的结构是静态的。
  - 节点的动态特征由一个特征张量 $\mathbf{X} \in \mathbb{R}^{N \times T_{in} \times F_{in}}$ 表示，其中 T_{in} 是输入窗口的时间步长，F_{in} 是每个时间步的特征维度。
- **输出**: 对于图中的每一个节点，我们期望模型能够生成：
  - 一个类别预测 $\hat{\mathbf{Y}} \in \{1, \ldots, C\}^N$，其中 C 是类别总数（例如，正常、某类攻击等）。
  - 一个相应的认知不确定性（Epistemic Uncertainty）得分 $\mathbf{U} \in \mathbb{R}^N$，用以量化模型对其预测的置信度。
- **目标**: 学习一个概率映射 $p(\mathbf{Y}, \mathbf{U} | \mathbf{X}, \mathbf{A})$，该映射不仅能提供准确的类别预测，还能对其预测给出可靠的不确定性度量，尤其是在面对分布外（Out-of-Distribution）或对抗性样本时。

2 模型架构：贝叶斯时空图神经网络

BSTGNF模型的核心思想是将确定性的时空图神经网络（STGNN）层替换为其贝叶斯对应项。我们不再学习一个单一的权重集 $\mathbf{W}$ 的点估计，而是致力于学习其后验分布 $p(\mathbf{W}|\mathcal{D}_{\text{train}})$。由于该后验分布通常是难以直接计算的（intractable），我们采用变分推断（Variational Inference, VI）来学习其一个近似分布 $q(\mathbf{W}; \boldsymbol{\Theta})$。

2.1 变分分布假设

我们引入一个易于处理的、参数化的分布 $q(\mathbf{W};\mathbf{\Theta})$ 来近似真实的后验。一个常用且有效的选择是均场（对角）高斯分布，它假设所有权重之间相互独立：

$$q(\mathbf{W};\mathbf{\Theta}) = \prod_i \mathcal{N}(w_i;\mu_i,\sigma_i^2) \tag{1}$$

这里的变分参数 $\mathbf{\Theta} = \{\boldsymbol{\mu},\boldsymbol{\rho}\}$ 是模型需要学习的对象。我们学习 ρ_i 而非直接学习 σ_i，并通过 softplus 函数 $\sigma_i = \log(1+\exp(\rho_i))$ 来确保标准差 σ_i 始终为正。

2.2 贝叶斯时空块 (BST-Block)

模型由多个BST-Block堆叠而成。对于第 l 个块的输入张量 $\mathbf{H}^{(l)}$，其计算流程如下：

1. **贝叶斯时域卷积**: 首先，从权重的变分后验分布中采样时域卷积核：

$$\mathbf{W}_t^{(l)} \sim q(\mathbf{W};\boldsymbol{\mu}_t^{(l)},\boldsymbol{\rho}_t^{(l)}) \tag{2}$$

然后，提取时域特征：

$$\mathbf{H}_{\text{temp}} = \text{ReLU}(\text{Conv1D}(\mathbf{H}^{(l)},\mathbf{W}_t^{(l)})) \tag{3}$$

2. **贝叶斯图卷积**: 接着，为图卷积层采样权重：

$$\mathbf{W}_g^{(l)} \sim q(\mathbf{W};\boldsymbol{\mu}_g^{(l)},\boldsymbol{\rho}_g^{(l)}) \tag{4}$$

最终，该块的输出融合了时空信息：

$$\mathbf{H}^{(l+1)} = \text{ReLU}(\hat{\mathbf{A}}\mathbf{H}_{\text{temp}}\mathbf{W}_g^{(l)}) \tag{5}$$

其中 $\hat{\mathbf{A}} = \tilde{\mathbf{D}}^{-1/2}\tilde{\mathbf{A}}\tilde{\mathbf{D}}^{-1/2}$ 是对称归一化的、且包含自环的邻接矩阵（$\tilde{\mathbf{A}} = \mathbf{A}+\mathbf{I}$）。

3 模型训练：优化证据下界 (ELBO)

我们通过最大化证据下界（ELBO）来训练模型，ELBO是数据边际对数似然的一个下界。这等价于最小化负ELBO，也即我们的损失函数：

$$\mathcal{L}_{\text{ELBO}}(\mathbf{\Theta}) = \underbrace{-\mathbb{E}_{q(\mathbf{W};\mathbf{\Theta})}[\log p(\mathbf{Y}|\mathbf{X},\mathbf{A},\mathbf{W})]}_{\text{重建损失}} + \underbrace{\text{KL}[q(\mathbf{W};\mathbf{\Theta})||p(\mathbf{W})]}_{\text{复杂度损失 (正则项)}} \tag{6}$$

重建损失： 第一项是期望负对数似然。对于分类任务，它对应于交叉熵损失。在实践中，我们通过每次迭代中的单次蒙特卡洛采样来近似这个期望。

复杂度损失 (KL散度): 第二项是近似后验 $q(\mathbf{W};\mathbf{\Theta})$ 与一个预设的先验分布 $p(\mathbf{W})$ 之间的KL散度。我们通常选择一个简单的标准高斯分布作为先验，即 $p(\mathbf{W}) = \mathcal{N}(0, \mathbf{I})$。对于高斯形式的 q 和 p，该KL散度项有解析解：

$$\mathrm{KL}[\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\sigma}^2)||\mathcal{N}(0,1)] = \frac{1}{2}\sum_i (\sigma_i^2 + \mu_i^2 - 1 - \log \sigma_i^2) \tag{7}$$

Algorithm 1 BSTGNF 模型训练流程

输入: 训练集 $\mathcal{D}_{\text{train}} = \{(\mathbf{X}_i, \mathbf{A}_i, \mathbf{Y}_i)\}$, 学习率 η, 批大小 B, 训练轮次 E。
输出: 优化后的变分参数 $\mathbf{\Theta}^* = \{\boldsymbol{\mu}^*, \boldsymbol{\rho}^*\}$。
随机初始化变分参数 $\mathbf{\Theta} = \{\boldsymbol{\mu}, \boldsymbol{\rho}\}$。
for $e = 1$ **to** E **do**
  for batch in $\mathcal{D}_{\text{train}}$ **do**
    $(\mathbf{X}_b, \mathbf{A}_b, \mathbf{Y}_b) \leftarrow$ 从 $\mathcal{D}_{\text{train}}$ 中采样一个大小为 B 的批次。
    ▷ — 随机前向传播 —
    使用**重参数化技巧**从 $q(\mathbf{W};\mathbf{\Theta})$ 中采样权重 $\mathbf{W}_{\text{sample}}$:
    $\boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I})$
    $\boldsymbol{\sigma} = \log(1 + \exp(\boldsymbol{\rho}))$
    $\mathbf{W}_{\text{sample}} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\epsilon}$
    计算 Logits: $\mathbf{Z} = \text{BSTGNF}_{\text{forward}}(\mathbf{X}_b, \mathbf{A}_b, \mathbf{W}_{\text{sample}})$
    ▷ — 计算 ELBO 损失 —
    $\mathcal{L}_{\text{rec}} \leftarrow \text{CrossEntropy}(\text{Softmax}(\mathbf{Z}), \mathbf{Y}_b)$
    $\mathcal{L}_{\text{KL}} \leftarrow \sum_i \frac{1}{2}(\sigma_i^2 + \mu_i^2 - 1 - \log \sigma_i^2)$
    $\mathcal{L}_{\text{total}} \leftarrow \mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{KL}}$
    ▷ — 反向传播与参数更新 —
    计算梯度 $\nabla_{\mathbf{\Theta}} \mathcal{L}_{\text{total}}$。
    使用Adam优化器更新参数: $\mathbf{\Theta} \leftarrow \text{Adam}(\mathbf{\Theta}, \nabla_{\mathbf{\Theta}}, \eta)$。
return $\mathbf{\Theta}^*$

4 推理与不确定性量化

在推理阶段，我们使用训练好的变分分布 $q(\mathbf{W};\mathbf{\Theta}^*)$ 进行 M 次蒙特卡洛前向传播，以近似预测后验分布。

预测后验分布： 对于一个测试样本 $(\mathbf{X}_{\text{test}}, \mathbf{A}_{\text{test}})$，其预测后验分布由以下积分给出：

$$p(\mathbf{Y}^*|\mathbf{X}_{\text{test}}, \mathbf{A}_{\text{test}}, \mathcal{D}_{\text{train}}) = \int p(\mathbf{Y}^*|\mathbf{X}_{\text{test}}, \mathbf{A}_{\text{test}}, \mathbf{W}) p(\mathbf{W}|\mathcal{D}_{\text{train}}) d\mathbf{W} \tag{8}$$

我们通过蒙特卡洛采样来近似这个积分：

$$p(\mathbf{Y}^*|\dots) \approx \frac{1}{M} \sum_{m=1}^{M} p(\mathbf{Y}^*|\mathbf{X}_{\text{test}}, \mathbf{A}_{\text{test}}, \mathbf{W}_m), \quad \text{其中 } \mathbf{W}_m \sim q(\mathbf{W}; \boldsymbol{\Theta}^*) \tag{9}$$

我们记 $\mathbf{p}_m = \text{Softmax}(\text{BSTGNF}_{\text{forward}}(\mathbf{X}_{\text{test}}, \mathbf{A}_{\text{test}}, \mathbf{W}_m))$ 为第 m 次采样的预测概率向量。

最终预测与不确定性度量：

- **最终预测：** 最终的类别预测通过对 M 次预测概率取平均，然后选择概率最大的类别得到：

$$\bar{\mathbf{p}} = \frac{1}{M} \sum_{m=1}^{M} \mathbf{p}_m, \quad \hat{\mathbf{Y}} = \text{argmax}(\bar{\mathbf{p}}) \tag{10}$$

- **认知不确定性：** 我们使用预测与模型后验之间的**互信息**来量化模型的认知不确定性。该值可以通过采样结果计算得出：

$$\mathcal{I}(\mathbf{Y}^*; \mathbf{W}|\mathbf{X}_{\text{test}}, \mathcal{D}_{\text{train}}) = \underbrace{\mathcal{H}\left(\frac{1}{M} \sum_{m=1}^{M} \mathbf{p}_m\right)}_{\text{预测均值的熵}} - \underbrace{\frac{1}{M} \sum_{m=1}^{M} \mathcal{H}(\mathbf{p}_m)}_{\text{预测熵的均值}} \tag{11}$$

其中 $\mathcal{H}(\mathbf{p}) = -\sum_c p_c \log p_c$ 是香农熵。一个较高的互信息得分意味着，从后验中采样的不同模型参数会导致显著不同的预测结果，这标志着模型存在较高的不确定性。

Algorithm 2 BSTGNF 推理与不确定性量化流程

输入: 优化后的参数 $\boldsymbol{\Theta}^*$, 测试样本 $(\mathbf{X}_{\text{test}}, \mathbf{A}_{\text{test}})$, 蒙特卡洛采样次数 M。

输出: 类别预测 $\hat{\mathbf{Y}}$, 认知不确定性得分 $\mathbf{U}_{\text{epistemic}}$。

初始化一个空的预测概率列表: $\mathcal{P} \leftarrow []$。

for $m = 1$ **to** M **do**

    通过重参数化技巧从 $q(\mathbf{W}; \boldsymbol{\Theta}^*)$ 中采样权重 $\mathbf{W}_m$。

    $\mathbf{Z}_m \leftarrow \text{BSTGNF}_{\text{forward}}(\mathbf{X}_{\text{test}}, \mathbf{A}_{\text{test}}, \mathbf{W}_m)$

    $\mathbf{p}_m \leftarrow \text{Softmax}(\mathbf{Z}_m)$

    将 $\mathbf{p}_m$ 添加到列表 $\mathcal{P}$。

▷ — 聚合采样结果以获得最终输出 —

$\bar{\mathbf{p}} \leftarrow \frac{1}{M} \sum_{\mathbf{p} \in \mathcal{P}} \mathbf{p}$

$\hat{\mathbf{Y}} \leftarrow \text{argmax}(\bar{\mathbf{p}})$ ▷ 最终类别预测

$H_{\text{mean_pred}} \leftarrow -\sum_c \bar{p}_c \log \bar{p}_c$ ▷ 预测均值的熵

$E_{\text{pred_entropy}} \leftarrow \frac{1}{M} \sum_{\mathbf{p} \in \mathcal{P}} (-\sum_c p_c \log p_c)$ ▷ 预测熵的均值

$\mathbf{U}_{\text{epistemic}} \leftarrow H_{\text{mean_pred}} - E_{\text{pred_entropy}}$ ▷ 不确定性得分

return $\hat{\mathbf{Y}}, \mathbf{U}_{\text{epistemic}}$